



MANUAL OFICIAL DE INGENIERÍA E INFRAESTRUCTURA CLOUD

Manual de Instalación y Despliegue en Google Cloud Paso a Paso

Guía de aprovisionamiento de infraestructura Serverless (Cloud Run, Cloud Firestore Nativo, Vertex AI, Artifact Registry), configuración de IAM con mínimo privilegio, Firebase Auth y resolución forense de incidentes.

Google Cloud Run

Cloud Firestore Nativo

Vertex AI & Gemini API

Artifact Registry

Zero-Trust IAM

Docker & Cloud Build

Identificador Documental:	DOC-AEGIS-DEPLOY-2026-V2
Público Objetivo:	Ingenieros DevOps, SysAdmins, Arquitectos Cloud, CISOs y Líderes Técnicos
Autor / Arquitecto Líder:	AegisAI Open Source Community & Core Security Engineering Team
Servicios Cloud Clave:	Cloud Run, Firestore (Modo Nativo), Vertex AI, Artifact Registry, Firebase Auth
Versión de Plataforma:	AegisAI v2.5 Enterprise (Edición Google Cloud)
Fecha de Liberación:	25 de Septiembre de 2026
Clasificación:	Open Source / Public Community Release (Apache 2.0)




Indice de Contenido

- 1. 1. Resumen Ejecutivo y Topología de Infraestructura — Arquitectura Serverless desacoplada en Google Cloud.
- 2. 2. Requisitos Previos y Permisos IAM — Cuenta de facturación, roles de IAM y Google Cloud Shell.
- 3. 3. Método 1: Despliegue Automatizado en 1 Solo Paso — Ejecución rápida con `deploy_ccloud_run.sh`.
- 4. 4. Método 2: Despliegue Manual Paso a Paso (12 Fases) — Configuración detallada paso a paso mediante `gcloud` CLI.
- 5. 5. Configuración de Firebase Authentication y Dominios — Google OAuth, SDK Web y dominios autorizados.
- 6. 6. Configuración de Modelos y Multi-Proveedor en Caliente — Gemini API, Vertex AI, OpenRouter y vLLM.
- 7. 7. Verificación Operativa y Pruebas de Humo — Endpoints de salud, cabeceras HTTP y suites de prueba.
- 8. 8. Guía Forense de Solución de Problemas (Troubleshooting) — Resolución de los 6 incidentes más habituales.
- 9. 9. Mantenimiento y Actualizaciones Zero-Downtime — Actualizaciones continuas sin interrupción de servicio.

1. Resumen Ejecutivo y Topología de Infraestructura

AegisAI ha sido concebida bajo un modelo **Cloud-Native Serverless** en Google Cloud Platform. Este diseño garantiza alta resiliencia, escalabilidad automática de 0 a 10 instancias según demanda y costos optimizados bajo demanda (Pay-as-you-go).



2. Requisitos Previos y Permisos IAM

Para aprovisionar AegisAI en Google Cloud, se requiere:

MANUAL DE INSTALACIÓN Y DESPLIEGUE EN GOOGLE CLOUD

- **Proyecto Activo en Google Cloud:** Con facturación (Cloud Billing) habilitada.

AegisAI Public · Documentación Técnica Oficial Documentación Oficial de Ingeniería 2024 · Versión 2.0

• **Roles IAM del Desplegador:** roles/owner o combinación de roles/resourceManager.projectIamAdmin, roles/run.admin, roles/artifactregistry.admin, roles/cloudbuild.builds.editor, roles/datastore.owner y roles/iam.serviceAccountAdmin.

- **Entorno Recomendado: Google Cloud Shell** (<https://shell.cloud.google.com>), el cual dispone de gcloud, docker, git, node y autenticación nativa preconfigurados.
- **Clave de API Gemini:** Clave gratuita o corporativa obtenida en Google AI Studio (<https://aistudio.google.com>) o mediante credenciales de Vertex AI.

3. Método 1: Despliegue Rápido Automatizado (1 Solo Paso)

El repositorio incluye el orquestador `deploy_cloud_run.sh` que automatiza las 12 fases del aprovisionamiento:

```
# Otorgar permisos y ejecutar con el ID del proyecto GCP
chmod +x deploy_cloud_run.sh
./deploy_cloud_run.sh ID_DE_TU_PROYECTO_GCP
```

El script validará dependencias, habilitará las APIs, configurará las cuentas de servicio, creará la base de datos Firestore y compilará la imagen en Cloud Build, imprimiendo al final la URL pública lista para operar.



4. Método 2: Despliegue Manual Paso a Paso (12 Fases Secuenciales)

Si las políticas corporativas exigen la ejecución de comandos auditados paso a paso:

Paso 4.1: Definir Variables de Entorno y Proyecto Activo

```
export PROJECT_ID="tu-proyecto-gcp-id"
export REGION="us-central1"
export SERVICE_NAME="aegis-ai"
export REPO_NAME="cloud-run-source-deploy"
export ALLOWED_DOMAINS="*"
export GEMINI_API_KEY="AIzaSy..."

gcloud config set project "$PROJECT_ID"
```

Paso 4.2: Habilitar las 8 APIs Requeridas de Google Cloud

```
gcloud services enable run.googleapis.com cloudbuild.googleapis.com artifactregistry.googleapis.com
```

Paso 4.3: Otorgar Permisos IAM a Cloud Build

```
PROJECT_NUMBER=$(gcloud projects describe "$PROJECT_ID" --format="value(projectNumber)")
COMPUTE_SA="${PROJECT_NUMBER}-compute@developer.gserviceaccount.com"

gcloud projects add-iam-policy-binding "$PROJECT_ID" --member="serviceAccount:${COMPUTE_SA}" --role="roles/cloudbuild.builder"
gcloud projects add-iam-policy-binding "$PROJECT_ID" --member="serviceAccount:${COMPUTE_SA}" --role="roles/cloudbuild.build"
gcloud projects add-iam-policy-binding "$PROJECT_ID" --member="serviceAccount:${COMPUTE_SA}" --role="roles/cloudbuild.build"
gcloud projects add-iam-policy-binding "$PROJECT_ID" --member="serviceAccount:${COMPUTE_SA}" --role="roles/cloudbuild.build"
```

Paso 4.4: Crear la Service Account de Ejecución (aegis-runner-sa)

Por principio de mínimo privilegio, no se utiliza la cuenta Compute por defecto:

```
SA_EMAIL="aegis-runner-sa@${PROJECT_ID}.iam.gserviceaccount.com"

gcloud iam service-accounts create aegis-runner-sa --description="Identidad de ejecucion para AegisAI"

# Inferencia en Vertex AI
gcloud projects add-iam-policy-binding "$PROJECT_ID" --member="serviceAccount:${SA_EMAIL}" --role="roles/aiplatform.user"

# Almacenamiento en Firestore
gcloud projects add-iam-policy-binding "$PROJECT_ID" --member="serviceAccount:${SA_EMAIL}" --role="roles/firestore.dataOwner"

# Lectura de infraestructura para el GCP Live Scanner
gcloud projects add-iam-policy-binding "$PROJECT_ID" --member="serviceAccount:${SA_EMAIL}" --role="roles/cloudasset.viewer"
```

Paso 4.5: Provisionar Cloud Firestore en Modo Nativo

```
gcloud firestore databases create --location="nam5" --type="firestore-native" --project="$PROJ"
AegisAI Public · Documentación Técnica Oficial
Documentación Oficial de Ingeniería 2026 · Versión 2.0
```

Paso 4.6: Configurar Firebase Authentication y Google Sign-In

1. Ingrese a **Firebase Console** (https://console.firebase.google.com/project/_/authentication/providers).
2. En la pestaña **Sign-in method**, active el proveedor **Google** y guarde.
3. En **Project Settings > General > Tus apps**, registre una app Web (`</>`) llamada **AegisAI** .
4. Guarde la configuración en `firebase-applet-config.json` en la raíz del proyecto.



Paso 4.7: Crear el Repositorio en Artifact Registry

AegisAI Public · Documentación Técnica Oficial

Documentación Oficial de Ingeniería 2026 · Versión 2.0

```
gcloud artifacts repositories create "$REPO_NAME" --repository-format=docker --location="$REGION"
```

Paso 4.8: Compilar la Imagen del Contenedor con Cloud Build

```
IMAGE_URL="${REGION}-docker.pkg.dev/${PROJECT_ID}/${REPO_NAME}/${SERVICE_NAME}:latest"
```

```
gcloud builds submit --tag "$IMAGE_URL" --project="$PROJECT_ID" .
```

Paso 4.9: Desplegar el Servicio en Google Cloud Run

```
ENV_VARS_EXTRA=""
if [ -n "$GEMINI_API_KEY" ]; then
    ENV_VARS_EXTRA=", GEMINI_API_KEY=${GEMINI_API_KEY}"
fi
```

```
gcloud run deploy "$SERVICE_NAME" --image "$IMAGE_URL" --project "$PROJECT_ID" --region "$REGION"
```

Paso 4.10: Autorizar el Dominio de Cloud Run en Firebase Authentication

```
# Obtener la URL del servicio
SERVICE_URL=$(gcloud run services describe "$SERVICE_NAME" --project "$PROJECT_ID" --region "$REGION")
echo "URL asignada: ${SERVICE_URL}"
```

Copie el dominio sin protocolo (ej. `aegis-ai-607603788049.us-central1.run.app`) y agréguelo en **Firebase Console** > **Authentication** > **Settings** > **Authorized domains**.

Paso 4.11: Pruebas de Humo (Smoke Tests)

```
# 1. Endpoint de salud
curl -s "${SERVICE_URL}/api/health"
# Respuesta: {"status":"ok"}

# 2. Cabeceras de seguridad HTTP
curl -I "${SERVICE_URL}"
# Debe incluir: X-Content-Type-Options: nosniff, X-Frame-Options: SAMEORIGIN
```

Paso 4.12: Configuración de Claves de IA y Multi-Proveedor en Caliente

Abra la URL del servicio en el navegador, inicie sesión y acceda a **Configuración / Admin** (⚙️) para parametrizar o alternar entre proveedores de IA (Google Gemini, OpenRouter, OpenAI o vLLM on-premise) en caliente.

5. Guía Forense de Solución de Problemas (Troubleshooting)



INCIDENTE / ERROR	CAUSA RAÍZ	RESOLUCIÓN INMEDIATA
AegisAI Public - Documentación Técnica Oficial Documentación Oficial de Ingeniería 2026 - Versión 2.0		
PERMISSION_DENIED en Cloud Storage	La cuenta {NUM}-compute@developer.gserviceaccount.com no tiene permisos para escribir en el bucket de staging de Cloud Build.	gcloud projects add-iam-policy-binding "\$PROJECT_ID" --member="serviceAccount:\${COMPUTE_SA}" --role="roles/storage.admin"
auth/UnauthorizedDomain	El dominio de Cloud Run no ha sido dado de alta en la lista blanca de Firebase OAuth.	Agregue el dominio asignado en Firebase Console > Authentication > Settings > Authorized domains.
Identity Toolkit API has not been used	La API de Firebase Auth no fue habilitada durante la inicialización.	gcloud services enable identitytoolkit.googleapis.com --project="\$PROJECT_ID"
Container failed to start and listen on PORT=8080	Falta de dependencias en runtime o error no capturado en Node.js.	Inspeccione los logs detallados con: gcloud run services logs read "\$SERVICE_NAME" --region "\$REGION" --limit 50
FAILED_PRECONDITION: Policy member restriction	La organización prohíbe allUsers mediante la directiva iam.allowedPolicyMemberDomains .	Asigne el rol de invocador al dominio corporativo: gcloud run services add-iam-policy-binding "\$SERVICE_NAME" --member="domain:tuempresa.com" --role="roles/run.invoker"
PERMISSION_DENIED en Cloud Firestore	La base de datos Firestore no ha sido inicializada en modo Nativo.	gcloud firestore databases create --location="nam5" --type="firestore-native" --project="\$PROJECT_ID"

6. Mantenimiento y Actualizaciones Zero-Downtime

Para aplicar nuevas revisiones o actualizaciones de frameworks normativos sin interrumpir a los usuarios:

```
git pull origin main
./deploy_cloud_run.sh "$PROJECT_ID"
```

Google Cloud Run ejecutará la nueva revisión en paralelo, validará las sondas de salud y migrará el 100% del tráfico de forma instantánea sin pérdida de conexiones activas.